

De la percepción privilegiada a los píxeles: destilación de políticas para conducción autónoma en simulación

Resumen—Comparamos seis representaciones de la observación para un agente de conducción autónoma entrenado con PPO en el simulador Webots. Manteniendo *idénticos* el entorno, la recompensa, el presupuesto de entrenamiento (1M de pasos) y la configuración del algoritmo, variamos únicamente la observación: un agente geométrico *privilegiado* (features de calzada extraídas de la cámara), cuatro agentes de visión entrenados con RL (un frame, un frame *sin propiocepción*, cuatro frames apilados y una política recurrente con LSTM), y un agente de visión *destilado* del geométrico por clonación de comportamiento. Sobre pistas no vistas y con randomización del fondo, el agente destilado se acerca al maestro privilegiado —92.5 % frente a 97.0 % de vueltas completadas— y es la única variante de visión estable (las cinco seeds convergen), mientras completa la vuelta en menos pasos de control; entrenar la visión directamente con RL es inestable —algunas seeds colapsan— y agregar estructura temporal (apilado, recurrencia) *empeora* el desempeño. Mapas de saliencia por *oclusión* muestran que la destilación desplaza la atención de la CNN del fondo hacia la calzada, lo que explica su invarianza al entorno. Concluimos que el cuello de botella de la visión-RL no es la *capacidad* de la representación sino la *asignación de crédito* a través de píxeles en un problema parcialmente observable, y que la destilación privilegiada lo esquiva con targets supervisados densos.

Index Terms—aprendizaje por refuerzo, clonación de comportamiento, destilación de políticas, conducción autónoma, aprendizaje privilegiado, randomización de dominio

I. INTRODUCCIÓN

Un agente de conducción autónoma que percibe el mundo *solo* a través de una cámara enfrenta un problema doblemente difícil: la observación visual es *parcial* —un frame congela la escena: no muestra qué hay tras la próxima curva ni cómo evoluciona el entorno— y la señal de aprendizaje es *escasa*, la recompensa por avanzar en pista. En este régimen, una red convolucional entrenada con RL tiende a encontrar un *atajo*: se aferra a la textura del fondo (la pared y el horizonte de la arena), que es constante durante el entrenamiento pero no lleva información útil de la calzada. El resultado es una política frágil que conduce mientras el fondo no cambie.

Atacamos el problema por dos vías complementarias. **Randomización de dominio del fondo**: rotamos la textura de la pared y el *skybox* por episodio, para que el fondo deje de ser una señal aprovechable. **Destilación privilegiada**: en lugar de aprender de la recompensa, el estudiante de visión imita las decisiones de un maestro que ya percibe la calzada de forma limpia —heredando *qué mirar*— siguiendo la línea de *Learning by Cheating* [1].

Nuestra contribución es un estudio controlado, con 5 seeds por modelo (30 modelos en total), que aísla el efecto de la *representación de la observación*, dejando todo lo demás fijo. Mostramos que (i) la visión destilada se acerca al maestro privilegiado y es la única variante de visión *confiable* (baja varianza entre seeds); (ii) la visión-RL directa es una lotería entre seeds y la temporalidad la empeora; y (iii) la saliencia confirma que la ventaja es de invarianza al entorno.

II. TRABAJO RELACIONADO

La **destilación de un agente privilegiado** a uno de visión es la base directa de este trabajo: *Learning by Cheating* [1] entrena primero un agente con acceso al estado del simulador y luego lo clona a una política sensorimotora. La **clonación de comportamiento** ingenua sufre corrimiento de covariables, formalizado por DAGger [2]: el alumno visita estados que el maestro nunca demostró. DART [3] mitiga esto inyectando ruido en la acción del maestro durante la colecta, cubriendo estados de recuperación; usamos exactamente esta idea con $\sigma = 0.15$. La **randomización de dominio** [4] fuerza invarianza randomizando lo irrelevante —aquí, el fondo. El agente base se entrena con PPO [5] y el extractor visual es la NatureCNN [6]. El escenario está inspirado en la plataforma AWS DeepRacer [7].

III. MÉTODO

Las seis variantes comparten entorno, recompensa, presupuesto (1M pasos) y configuración de PPO; **lo único que cambia es la observación** (Tabla I). La acción es un vector continuo de dos componentes —las velocidades normalizadas de las ruedas izquierda y derecha (tracción diferencial), cada una remapeada a $[v_{\min}, v_{\max}]$ rad/s— y la recompensa es densa: progreso sobre la pista menos penalizaciones, computada desde la misma imagen de cámara.

Tabla I
LAS SEIS REPRESENTACIONES DE LA OBSERVACIÓN.

Variante	Régimen	Observación
Geométrica	privilegiado	Vector de 9 features de percepción.
Visión 1 frame	visión-RL	CNN sobre un frame RGB crudo. La variante de visión más simple.
Visión pura (cámara)	visión-RL	CNN de 1 frame <i>sin</i> la velocidad propioceptiva: solo píxeles (ablación).
Visión apilada	visión-RL	Cuatro frames apilados para dar información temporal.
Visión + LSTM	visión-RL	Política recurrente: la memoria la aporta el LSTM.
Visión destilada	destilado (BC)	CNN de 1 frame entrenada por clonación para imitar al maestro geométrico.

III-A. El pipeline de destilación

Una misma cámara alimenta dos caminos (Fig. 1). El *baseline* entrena la visión con RL directo desde la recompensa. *Nuestro método* primero entrena un maestro geométrico privilegiado, colecta sus decisiones con ruido DART y entrena por clonación (MSE sobre la acción) un estudiante de visión que hereda *qué mirar*. La clonación de comportamiento **cambia la naturaleza del problema**: en lugar de optimizar la visión por refuerzo desde la recompensa —con su *asignación de crédito* (*credit assignment*) de alta varianza a través de píxeles— resuelve un aprendizaje *supervisado* directo con targets densos, mucho más fácil de optimizar. El estudiante usa *exactamente* la misma arquitectura (NatureCNN, 1 frame) que la variante Visión 1 frame, de modo que la única diferencia es el *régimen de entrenamiento*.




Figura 1. El pipeline. Una cámara alimenta dos caminos: arriba, nuestro método (maestro geométrico privilegiado → colecta con DART → clonación a un estudiante de visión); abajo, el baseline de visión-RL directo, que sobreajusta el fondo.

IV. SETUP EXPERIMENTAL

El simulador es Webots R2025a y el agente se implementa sobre Stable-Baselines3 (PPO) [5] y sb3-contrib (RecurrentPPO). Adoptamos PPO como algoritmo base por su estabilidad y eficiencia demostradas en control continuo y navegación autónoma. La observación de visión combina una imagen RGB $84 \times 84 \times 3$ (multiplicada por el número de frames apilados) con una lectura *propioceptiva* de velocidad del cuerpo (*forward* y *yaw-rate*, tomada del ground-truth del simulador); la observación geométrica reemplaza la imagen por un vector de

9 features de percepción —esas mismas 2 de velocidad más 7 de calzada (road-fraction, verde central y 5 offsets laterales de look-ahead). Así, **todas las variantes comparten la velocidad propioceptiva**; lo único que cambia es cómo perciben la pista (imagen cruda vs. features explícitas). La política de visión es en consecuencia *MultiInput*: una NatureCNN sobre la imagen y un MLP sobre la velocidad. La randomización de dominio rota la textura de la pared y el *skybox* por episodio. La evaluación usa dos pistas no vistas (*track9*, *track10*; Fig. 2), 20 episodios por pista, con fondo aleatorio y seed de reinicio fija (*eval-seed 0*) para que todos los modelos vean exactamente la misma secuencia de episodios. Las tablas II y III listan los hiperparámetros reales de los runs finales.

ENTRENAMIENTO — 8 pistas (ejemplos)



EVALUACIÓN — 2 pistas no vistas (held-out)




Figura 2. Pistas del estudio (mapas top-down: verde=fuera de pista, asfalto negro, línea de centro amarilla). **Arriba**: tres de las ocho pistas de *entrenamiento* (una por episodio, con fondo aleatorio). **Abajo**: las dos pistas de *evaluación* —no vistas en entrenamiento— de la misma distribución pero con curvas más cerradas.

Tabla II
HIPERPARÁMETROS DE PPO (LAS CINCO VARIANTES RL).

Algoritmo	PPO (Stable-Baselines3)
Política	MultiInput Actor-Critic (NatureCNN + MLP)
Pasos totales	1 000 000
Entornos paralelos	4
<i>n_steps</i> / rollout	256 (1024/actualización)
Batch · Épocas	128 · 5
Learning rate	5×10^{-4}
$\gamma \cdot \text{clip} \cdot \text{ent} \cdot \text{vf}$	$0.995 \cdot 0.2 \cdot 0.02 \cdot 0.5$
Normalización	VecNormalize (reward)
Seeds	0, 1, 2, 3, 4

Tabla III
HIPERPARÁMETROS DE LA DESTILACIÓN (CLONACIÓN DE COMPORTAMIENTO).

Objetivo	Clonación de comportamiento (MSE)
Maestro	Geométrico, misma seed que el alumno
Colecta	Apareada: limpia ($\sigma=0$) + DART ($\sigma=0.15$)
Pares (s, a)	$\sim 55\,000$ por seed
Épocas $\cdot$ LR	$30 \cdot 3 \times 10^{-4}$
Backbone	NatureCNN, 1 frame

V. RESULTADOS

Evaluamos las seis variantes (30 modelos) sobre pistas no vistas con fondo aleatorio. La métrica principal es la fracción de vueltas completadas (*lap rate*). La Tabla IV resume el desempeño medio y la Fig. 3 lo grafica.




Figura 3. Lap rate en pistas no vistas por variante (5 seeds, fondo aleatorio). La geométrica y la destilada quedan arriba y con barras angostas; la visión-RL cae y, sobre todo, se vuelve *inestable*.

El hallazgo central: la **visión destilada se acerca al maestro privilegiado y es la única variante de visión confiable**. Completa el 92.5 % de las vueltas (IQM 92.5 % frente a 97.5 % del maestro; una diferencia de ~ 5 puntos) pero, a diferencia de las de visión-RL, lo hace *sin colapsos*: su IC *bootstrap* del 95 % es angosto ([87, 98]) mientras que los de la visión-RL directa abarcan casi todo el rango (p.ej. apilada [21, 89], LSTM [33, 89]). Para evaluar la cercanía al maestro de forma directa aplicamos un TOST (*two one-sided tests*) sobre el lap rate por seed, con un margen de equivalencia pre-especificado de ± 5 puntos: con $n=5$ el test **no llega a declarar equivalencia** ($p_{\text{TOST}} = 0.43$; IC del 90 % de la diferencia $[-1.1, +10.1]$ puntos), lo que refleja tanto el *escaso poder de cinco seeds* como una brecha pequeña pero real de unos 5 puntos: la destilada hereda el techo del maestro pero no lo iguala punto por punto. La dispersión está dominada por la variabilidad *entre seeds* (irreducible con más episodios de evaluación), de modo que la equivalencia estricta solo quedaría establecida bajo un margen más laxo o con del orden de 20–30 seeds por condición. Con esa cautela, la destilada es además el **conductor confiable más rápido**: completa la vuelta en menos pasos de control que el maestro (766 vs. 983), partiendo solo de píxeles.

La propiocepción importa. Quitarle al agente de un frame las dos features de velocidad —dejándolo con *solo píxeles* (Visión pura)— baja el lap rate de 90.0 a 75.0 (IQM) y más que duplica el off-track ($7.5 \rightarrow 19.2$), además de agregar inestabilidad (una seed colapsa a 10 %): incluso la visión más simple se apoya en la velocidad propioceptiva como muleta, y los píxeles solos son un problema más duro.

V-A. *La visión-RL es una lotería; la destilación, no*

El promedio esconde lo esencial. La Tabla V muestra el lap rate por seed: las variantes temporales son **bimodales** — algunas seeds convergen y otras colapsan (apilada de 0 a 98, LSTM de 28 a 93)— mientras que el maestro y la destilada rinden parejo en las cinco. La enorme varianza de apilada y LSTM es el síntoma: la temporalidad agrega *dificultad de optimización*, no desempeño. Diagnósticos de entrenamiento (divergencia de KL, *explained variance* negativa del crítico) confirman una optimización inestable. Las curvas de entrenamiento (Fig. 4) lo hacen visible: la visión-RL aprende más lento y con bandas más anchas que el maestro.

Tabla V
LAP RATE (%) POR SEED. VERDE ≥ 85 , ROJO < 50 .

Variante	s0	s1	s2	s3	s4
Geométrica	93	98	100	95	100
Visión destilada	90	95	85	100	93
Visión 1 frame	90	95	58	98	85
Visión pura (cám.)	58	80	10	88	93
Visión apilada	63	98	73	0	65
Visión + LSTM	45	28	93	80	83




Figura 4. Curvas de entrenamiento de las variantes RL (5 seeds, banda = $\pm$ desvío). Izquierda: reward por episodio. Derecha: lap rate en pistas no vistas durante el entrenamiento. La destilada es supervisada y no aparece en estas curvas de RL.

VI. ANÁLISIS: QUÉ MIRA LA CNN

Para entender *por qué* la destilación funciona, medimos la *sensibilidad por oclusión* [8]: tapamos cada región de la imagen con un parche gris y medimos cuánto cambia el *steering* (el diferencial de ruedas que gobierna el giro). Donde tapar cambia más la decisión, más depende la política de esa región. A diferencia de los métodos de gradiente (guided backprop, *integrated gradients*), la oclusión mide el efecto *causal* sobre la salida; usamos el *steering* —no el valor $V(s)$ — porque en la destilada la cabeza de valor no se entrena (la

Tabla IV

DESEMPEÑO EN PISTAS NO VISTAS (FONDO ALEATORIO), AGREGADO SOBRE LAS 5 SEEDS DE CADA VARIANTE. CADA COLUMNA NUMÉRICA REPORTA **IQM[IC 95 %]**: LA *media intercuartil* —PROMEDIA EL 50 % CENTRAL DE LAS SEEDS, DESCARTANDO EL 25 % MEJOR Y EL 25 % PEOR; MÁS ROBUSTA QUE LA MEDIA SIMPLE FRENTE A SEEDS QUE COLAPSAN— SEGUIDA, ENTRE CORCHETES, DE SU *intervalo de confianza del 95 %* ESTIMADO POR *bootstrap* DE PERCENTIL (2×10^4 REMUESTREOS). EN *lap rate* Y *reward* MÁS ALTO ES MEJOR; EN *off-track* Y *pasos por vuelta*, MÁS BAJO. MEDIMOS LA RAPIDEZ EN **PASOS DE CONTROL POR VUELTA** (NO EN SEGUNDOS: ESTOS DEPENDEN DE LA VELOCIDAD DE SIMULACIÓN) Y ES *condicional a completar la vuelta*. FILAS RESALTADAS: LAS DOS VARIANTES QUE RESUELVEN LA TAREA DE FORMA CONFIABLE.

Variante	Régimen	Lap rate (%)	Off-track (%)	Pasos/vuelta	Reward/ep
Geométrica	privilegiado (RL)	97.5 [93, 100]	1.7 [0, 5.8]	983 [975, 1036]	179 [174, 184]
Visión destilada	destilado (BC)	92.5 [87, 98]	7.5 [1.7, 13.3]	766 [751, 807]	139 [131, 143]
Visión 1 frame	visión-RL	90.0 [67, 97]	7.5 [0.8, 33.3]	769 [684, 818]	134 [88, 173]
Visión pura (cámara)	visión-RL	75.0 [26, 91]	19.2 [1.7, 70.0]	851 [689, 940]	126 [71, 185]
Visión apilada	visión-RL	66.7 [21, 89]	23.3 [5.8, 52.5]	740 [561, 963]	140 [96, 195]
Visión + LSTM	visión-RL	69.2 [33, 89]	30.8 [9.2, 66.7]	697 [639, 762]	82 [45, 106]

clonación solo ajusta la acción). La Fig. 5 compara las cuatro variantes de visión (seed 0).




Figura 5. Sensibilidad del *steering* por oclusión sobre una curva. Las variantes de visión-RL (1 frame, apilada, LSTM) concentran la sensibilidad en la franja del **horizonte** —el borde entre la calzada y el fondo (pared y montañas)—, del que dependen como atajo: solo el 26–41 % de la sensibilidad cae sobre la calzada. La **destilada** invierte el patrón: el 66 % cae sobre la **calzada** y el borde curvo del carril, heredando del maestro geométrico *qué mirar*. (Porcentaje promediado sobre frames de curva held-out; el mapa es un frame representativo.)

La lectura es directa: la visión-RL directa se apoya en el fondo, que correlaciona con la dirección del giro en el set de entrenamiento pero desaparece bajo randomización; la destilación *decorrelaciona* la política del fondo, y por eso se sostiene.

VII. LIMITACIONES

El estudio es **solo en simulación**: no evaluamos transferencia a hardware real, y el maestro usa features extraídas dentro del simulador que en el mundo real habría que estimar con percepción —el problema difícil. Dicho esto, la saliencia sugiere una hipótesis *optimista* sobre la transferencia: como el estudiante destilado aprendió a *mirar la calzada e ignorar el fondo* —justo lo que la randomización vuelve inservible—, es un candidato mucho más prometedor para *sim-to-real* que la visión-RL directa, que colapsaría al desaparecer el fondo específico de Webots del que depende. La **familia de pistas es acotada** (dos pistas no vistas de la misma distribución) y la **randomización de dominio es parcial** (varía pared y skybox, no geometría, iluminación ni cámara), de modo que cierra *este* atajo y no todos los posibles. Por construcción, el **estudiante hereda el techo del maestro**: la mejora en

pasos por vuelta proviene de acciones más suaves, no de una política estrictamente superior. Finalmente, la bimodalidad de la visión-RL sugiere alta **sensibilidad a la seed**; no realizamos un barrido exhaustivo que pudiera rescatar algunas seeds colapsadas.

VIII. CONCLUSIÓN

Un agente privilegiado con percepción limpia de la calzada resuelve la tarea (97 %), y *destilarlo* a un agente de visión recupera casi ese desempeño (92.5 %; una brecha pequeña de unos 5 puntos) —con la ventaja decisiva de ser la única variante de visión *estable*— y completando la vuelta en menos pasos de control. Entrenar la misma visión con RL directo es poco confiable, y la temporalidad la empeora. La randomización del fondo y la saliencia confirman que la ventaja es de *invarianza al entorno*: la destilada mira la calzada, no el horizonte. La lectura general es que el límite de la visión-RL no es la *capacidad* de la representación sino la *asignación de crédito* a través de píxeles en un problema parcialmente observable; la destilación privilegiada lo esquiva con targets supervisados densos del agente privilegiado. Código, modelos y una versión navegable del paper están disponibles en <https://github.com/fluchetti45/deepracer>.

REFERENCIAS

- [1] D. Chen, B. Zhou, V. Koltun, and P. Krähenbühl, “Learning by cheating,” in *Conference on Robot Learning (CoRL)*, 2019.
- [2] S. Ross, G. J. Gordon, and J. A. Bagnell, “A reduction of imitation learning and structured prediction to no-regret online learning,” in *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2011.
- [3] M. Laskey, J. Lee, R. Fox, A. Dragan, and K. Goldberg, “Dart: Noise injection for robust imitation learning,” in *Conference on Robot Learning (CoRL)*, 2017.
- [4] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, and P. Abbeel, “Domain randomization for transferring deep neural networks from simulation to the real world,” in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2017.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [6] V. Mnih, K. Kavukcuoglu, D. Silver *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.

- [7] B. Balaji, S. Mallya, S. Genc *et al.*, “Deepracer: Autonomous racing platform for experimentation with sim2real reinforcement learning,” in *IEEE International Conference on Robotics and Automation (ICRA)*, 2020.
- [8] M. D. Zeiler and R. Fergus, “Visualizing and understanding convolutional networks,” in *European Conference on Computer Vision (ECCV)*, 2014.