

De la percepción privilegiada a los píxeles: destilación de políticas para conducción autónoma en simulación

Faustino Luchetti
Proyecto de tesis
Universidad
fluchetti45@gmail.com

Resumen—Comparamos cinco representaciones de la observación para un agente de conducción autónoma estilo AWS DeepRacer, entrenado con PPO en el simulador Webots. Manteniendo idénticos el entorno, la recompensa, el presupuesto de entrenamiento (1M de pasos) y la configuración del algoritmo, variamos únicamente la observación: un agente geométrico *privilegiado* (features de calzada extraídas de la cámara), tres agentes de visión pura entrenados con RL (un cuadro, cuatro cuadros apilados, y una política recurrente con LSTM), y un agente de visión *destilado* del geométrico por clonación de comportamiento. Sobre pistas no vistas y con randomización del fondo, el agente destilado iguala al maestro privilegiado —95.5 % frente a 97.0 % de vueltas completadas, sin diferencia estadística ($p = 1.000$)— y lo supera en tiempo de vuelta, mientras que entrenar la visión directamente con RL es inestable y agregar estructura temporal (apilado, recurrencia) *empeora* el desempeño. Mapas de saliencia por *guided backprop* muestran que la destilación desplaza la atención de la CNN del fondo hacia la calzada, lo que explica su invarianza al entorno. Concluimos que el cuello de botella de la visión-RL no es la *capacidad* de la representación sino la *asignación de crédito* a través de píxeles en un problema parcialmente observable, y que la destilación privilegiada lo esquivaba con targets supervisados densos.

Index Terms—aprendizaje por refuerzo, clonación de comportamiento, destilación de políticas, conducción autónoma, aprendizaje privilegiado, randomización de dominio

I. INTRODUCCIÓN

Un agente de conducción autónoma que percibe el mundo *solo* a través de una cámara enfrenta un problema doblemente difícil: la observación es *parcial* —un cuadro no informa la velocidad ni hacia dónde gira la escena— y la señal de aprendizaje es *escasa*, la recompensa por avanzar en pista. En este régimen, una red convolucional entrenada con RL tiende a encontrar un *atajo*: se aferra a la textura del fondo (la pared y el horizonte de la arena), que es constante durante el entrenamiento pero no lleva información útil de la calzada. El resultado es una política frágil que conduce mientras el fondo no cambie.

Atacamos el problema por dos vías complementarias. **Randomización de dominio del fondo**: rotamos la textura de la pared y el *skybox* por episodio, para que el fondo deje de ser una señal aprovechable. **Destilación privilegiada**: en lugar de aprender de la recompensa, el estudiante de visión imita las decisiones de un maestro que ya percibe la calzada de

forma limpia —heredando *qué mirar*— siguiendo la línea de *Learning by Cheating* [1].

Nuestra contribución es un estudio controlado, con 5 semillas por condición (25 modelos en total), que aísla el efecto de la *representación de la observación* dejando todo lo demás fijo. Mostramos que (i) la visión destilada iguala estadísticamente al maestro privilegiado; (ii) la visión-RL directa es poco confiable y la temporalidad la empeora; y (iii) la saliencia confirma que la ventaja es de invarianza al entorno.

II. TRABAJO RELACIONADO

La **destilación de un agente privilegiado** a uno de visión es la base directa de este trabajo: *Learning by Cheating* [1] entrena primero un agente con acceso al estado del simulador y luego lo clona a una política sensorimotora. La **clonación de comportamiento** ingenua sufre corrimiento de covariables, formalizado por DAGger [2]: el alumno visita estados que el maestro nunca demostró. DART [3] mitiga esto inyectando ruido en la acción del maestro durante la colecta, cubriendo estados de recuperación; usamos exactamente esta idea con $\sigma = 0.15$. La **randomización de dominio** [4] fuerza invarianza randomizando lo irrelevante —aquí, el fondo. El agente base se entrena con PPO [5] y el extractor visual es la NatureCNN [6]. El escenario está inspirado en la plataforma AWS DeepRacer [7].

III. MÉTODO

Las cinco variantes comparten entorno, recompensa, presupuesto (10^6 pasos) y configuración de PPO; **lo único que cambia es la observación** (Tabla I). La acción es un vector continuo (steer, throttle) y la recompensa es densa: progreso sobre la pista menos penalizaciones, computada desde la misma imagen de cámara.

III-A. El pipeline de destilación

Una misma cámara alimenta dos caminos (Fig. 1). El *baseline* entrena la visión con RL directo desde la recompensa. **Nuestro método** primero entrena un maestro geométrico privilegiado, colecta sus decisiones con ruido DART y entrena por clonación (MSE sobre la acción) un estudiante de visión que hereda *qué mirar*. El estudiante usa *exactamente* la misma arquitectura (NatureCNN, 1 cuadro) que la variante Visión 1

Cuadro I
LAS CINCO REPRESENTACIONES DE LA OBSERVACIÓN.

Variante	Régimen	Observación
Geométrica	privilegiado	~9 features de calzada (road-fraction, offset lateral, heading) + velocidad. Techo de referencia.
Visión 1 cuadro	visión-RL	CNN sobre un cuadro RGB crudo. La visión pura mínima.
Visión apilada	visión-RL	Cuatro cuadros apilados para dar información temporal.
Visión + LSTM	visión-RL	Política recurrente: la memoria la aporta el LSTM.
Visión destilada	destilado (BC)	CNN de 1 cuadro entrenada por clonación para imitar al maestro geométrico.

Cuadro II
HIPERPARÁMETROS DE PPO (LAS CUATRO VARIANTES RL).

Algoritmo	PPO (Stable-Baselines3)
Política	MultiInput Actor-Critic (NatureCNN + MLP)
Pasos totales	1 000 000
Entornos paralelos	4
n_steps / rollout	256 (1024/actualización)
Batch · Épocas	128 · 5
Learning rate	5×10^{-4}
$\gamma \cdot \text{clip} \cdot \text{ent} \cdot \text{vf}$	$0.995 \cdot 0.2 \cdot 0.02 \cdot 0.5$
Normalización	VecNormalize (reward)
Semillas	0, 1, 2, 3, 4

Cuadro III
HIPERPARÁMETROS DE LA DESTILACIÓN (CLONACIÓN DE COMPORTAMIENTO).

Objetivo	Clonación de comportamiento (MSE)
Maestro	Geométrico, misma semilla que el alumno
Colecta	Apareada: limpia ($\sigma=0$) + DART ($\sigma=0.15$)
Pares (s, a)	~55 000 por semilla
Épocas · LR	$30 \cdot 3 \times 10^{-4}$
Backbone	NatureCNN, 1 cuadro




Figura 1. El pipeline. Una cámara alimenta dos caminos: arriba, nuestro método (maestro geométrico privilegiado → colecta con DART → clonación a un estudiante de visión); abajo, el baseline de visión-RL directo, que sobreajusta el fondo.

cuadro, de modo que la única diferencia es el *régimen de entrenamiento*.

IV. SETUP EXPERIMENTAL

El simulador es Webots R2025a y el agente se implementa sobre Stable-Baselines3 (PPO) [5] y sb3-contrib (RecurrentPPO). La observación de visión es una imagen RGB $84 \times 84 \times 3$ (multiplicada por el número de cuadros apilados); la observación geométrica es un vector de ~9 features de calzada más la velocidad. La randomización de dominio rota la textura de la pared y el *skybox* por episodio. La evaluación usa dos pistas no vistas (*track9*, *track10*), 20 episodios por pista, con fondo aleatorio y semilla de reinicio fija (*eval-seed* 0) para que todos los modelos vean exactamente la misma secuencia de episodios. Las tablas II y III listan los hiperparámetros reales de los runs finales.

V. RESULTADOS

Evaluamos las cinco variantes (25 modelos) sobre pistas no vistas con fondo aleatorio. La métrica principal es la fracción de vueltas completadas (*lap rate*). La Tabla IV resume el desempeño medio y la Fig. 2 lo grafica.

El hallazgo central: la **visión destilada es estadísticamente indistinguible del maestro privilegiado** (Tabla VI, $p = 1.000$ por Mann-Whitney exacto de dos colas sobre 5 semillas), y además es el *conductor confiable más rápido*: recupera la competencia del agente privilegiado partiendo solo de píxeles.




Figura 2. Lap rate en pistas no vistas por variante (5 semillas, fondo aleatorio). La geométrica y la destilada quedan arriba y con barras angostas; la visión-RL cae y, sobre todo, se vuelve *inestable*.

V-A. La visión-RL es una lotería; la destilación, no

El promedio esconde lo esencial. La Tabla V muestra el lap rate por semilla: las variantes temporales son **bimodales**—algunas semillas convergen y otras colapsan (de 5 a 100, de 0 a 82)— mientras que el maestro y la destilada rinden parejo en las cinco. La enorme varianza de apilada y LSTM es el síntoma: la temporalidad agrega *dificultad de optimización*, no desempeño. Diagnósticos de entrenamiento (divergencia de KL, *explained variance* negativa del crítico) confirman una optimización inestable.

VI. ANÁLISIS: QUÉ MIRA LA CNN

Para entender *por qué* la destilación funciona, calculamos saliencia por *guided backprop* [8]: el gradiente de la decisión (valor del crítico $V(s)$ y *steering*) respecto de los píxeles

Cuadro IV

DESEMPEÑO EN PISTAS NO VISTAS CON FONDO ALEATORIO (MEDIA $\pm$ DESVÍO SOBRE 5 SEMILLAS). FILAS RESALTADAS: AGENTES QUE RESUELVEN LA TAREA.

Variante	Régimen	Lap rate (%)	Off-track (%)	Tiempo vuelta (s)	Reward/ep
Geométrica	privilegiado (RL)	97.0 $\pm$ 4.1	3.0 $\pm$ 4.1	181 $\pm$ 22	534 $\pm$ 18
Visión destilada	destilado (BC)	95.5 $\pm$ 6.7	3.5 $\pm$ 4.9	161 $\pm$ 25	482 $\pm$ 37
Visión 1 cuadro	visión-RL	83.5 $\pm$ 13.4	7.0 $\pm$ 5.7	197 $\pm$ 31	406 $\pm$ 27
Visión apilada	visión-RL	57.5 $\pm$ 38.8	33.0 $\pm$ 33.0	—	382 $\pm$ 65
Visión + LSTM	visión-RL	37.0 $\pm$ 36.3	51.5 $\pm$ 26.2	—	284 $\pm$ 44

Cuadro V

LAP RATE (%) POR SEMILLA. VERDE $\geq$ 85, ROJO $<$ 50.

Variante	s0	s1	s2	s3	s4
Geométrica	100	98	98	90	100
Visión destilada	100	92	100	100	85
Visión 1 cuadro	90	92	60	90	85
Visión apilada	38	90	5	55	100
Visión + LSTM	5	65	0	32	82

Cuadro VI

SIGNIFICANCIA (MANN-WHITNEY EXACTO, DOS COLAS, SOBRE LAP RATE POR SEMILLA, $n=5$). * $p < 0.05$; ** $p < 0.01$; N.S. = NO SIGNIFICATIVO.

Comparación	p	Veredicto
Geométrica vs Destilada	1.000	sin diferencia
Geométrica vs 1 cuadro	0.032	*
Geométrica vs LSTM	0.008	**
Destilada vs LSTM	0.008	**
Destilada vs 1 cuadro	0.079	marginal
1 cuadro vs LSTM	0.032	*
Destilada vs apilada	0.103	n.s.
Geométrica vs apilada	0.127	n.s.

de entrada. Crucialmente, la saliencia se computa **sobre el mismo cuadro que se muestra** —una curva— y no como un promedio sobre cuadros distintos, que mezclaría rectas y curvas. La Fig. 3 compara las cuatro variantes de visión (todas semilla 0).

La lectura es directa: la visión-RL directa se apoya en el fondo, que correlaciona con la dirección del giro en el set de entrenamiento pero desaparece bajo randomización; la destilación *decorrelaciona* la política del fondo, y por eso se sostiene. La Fig. 4 muestra además que la visión-RL aprende más lento y con bandas más anchas que el maestro.

VII. LIMITACIONES

El estudio es **solo en simulación**: no evaluamos transferencia a hardware real, y el maestro usa features extraídas dentro del simulador que en el mundo real habría que estimar con percepción —el problema difícil. La **familia de pistas es acotada** (dos pistas no vistas de la misma distribución) y la **randomización de dominio es parcial** (varía pared y skybox, no geometría, iluminación ni cámara), de modo que

cierra *este* atajo y no todos los posibles. Por construcción, el **estudiante hereda el techo del maestro**: la mejora en tiempo de vuelta proviene de acciones más suaves, no de una política estrictamente superior. Finalmente, la bimodalidad de la visión-RL sugiere alta **sensibilidad a la semilla**; no realizamos un barrido exhaustivo que pudiera rescatar algunas semillas colapsadas.

VIII. CONCLUSIÓN

Un agente privilegiado con percepción limpia de la calzada resuelve la tarea (97 %), y *destilarlo* a visión pura recupera ese desempeño sin pérdida significativa (95.5 %, $p = 1.0$) y con mejor tiempo de vuelta. Entrenar la misma visión con RL directo es poco confiable, y la temporalidad la empeora. La randomización del fondo y la saliencia confirman que la ventaja es de *invarianza al entorno*: la destilada mira la calzada, no el horizonte. La lectura general es que el límite de la visión-RL no es la *capacidad* de la representación sino la *asignación de crédito* a través de píxeles en un problema parcialmente observable; la destilación privilegiada lo esquivó con targets supervisados densos del agente privilegiado. Código, modelos y una versión navegable del paper están disponibles en <https://github.com/fluchetti45/deepracer>.

Saliencia por-frame (guided backprop) — calculada sobre esta misma curva, sin promediar




Figura 3. Saliencia por *guided backprop* sobre una misma curva. Las tres variantes RL puras (1 cuadro, apilada, LSTM) encienden la saliencia en una franja sobre el **horizonte** —la pared y las montañas del fondo—: usan el entorno, constante en entrenamiento, como atajo. La **destilada** desplaza la atención hacia *abajo*, sobre la calzada y el borde curvo del carril, con el horizonte apagado: hereda del maestro geométrico *qué mirar*. Dentro de cada modelo, *value* y *steer* coinciden porque comparten el extractor CNN.




Figura 4. Curvas de entrenamiento de las variantes RL (5 semillas, banda $= \pm$ desvío). Izquierda: reward por episodio. Derecha: lap rate en pistas no vistas durante el entrenamiento. La destilada es supervisada y no aparece en estas curvas de RL.

REFERENCIAS

- [1] D. Chen, B. Zhou, V. Koltun, and P. Krähenbühl, “Learning by cheating,” in *Conference on Robot Learning (CoRL)*, 2019.
- [2] S. Ross, G. J. Gordon, and J. A. Bagnell, “A reduction of imitation learning and structured prediction to no-regret online learning,” in *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2011.
- [3] M. Laskey, J. Lee, R. Fox, A. Dragan, and K. Goldberg, “Dart: Noise injection for robust imitation learning,” in *Conference on Robot Learning (CoRL)*, 2017.
- [4] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, and P. Abbeel, “Domain randomization for transferring deep neural networks from simulation to the real world,” in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2017.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [6] V. Mnih, K. Kavukcuoglu, D. Silver *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [7] B. Balaji, S. Mallya, S. Genc *et al.*, “Deepracer: Autonomous racing platform for experimentation with sim2real reinforcement learning,” in *IEEE International Conference on Robotics and Automation (ICRA)*, 2020.
- [8] J. T. Springenberg, A. Dosovitskiy, T. Brox, and M. Riedmiller, “Striving for simplicity: The all convolutional net,” in *International Conference on Learning Representations (ICLR) Workshop*, 2015.