

De la percepción privilegiada a los píxeles: destilación de políticas para conducción autónoma en simulación

Resumen—Comparamos cinco representaciones de la observación para un agente de conducción autónoma entrenado con PPO en el simulador Webots. Manteniendo *idénticos* el entorno, la recompensa, el presupuesto de entrenamiento (1M de pasos) y la configuración del algoritmo, variamos únicamente la observación: un agente geométrico *privilegiado* (features de calzada extraídas de la cámara), tres agentes de visión entrenados con RL (un frame, cuatro frames apilados, y una política recurrente con LSTM), y un agente de visión *destilado* del geométrico por clonación de comportamiento. Sobre pistas no vistas y con randomización del fondo, el agente destilado alcanza al maestro privilegiado —95.5 % frente a 97.0 % de vueltas completadas, una diferencia pequeña y sin evidencia de superioridad de ninguno— y lo supera en tiempo de vuelta, mientras que entrenar la visión directamente con RL es inestable y agregar estructura temporal (apilado, recurrencia) *empeora* el desempeño. Mapas de saliencia por *guided backprop* muestran que la destilación desplaza la atención de la CNN del fondo hacia la calzada, lo que explica su invarianza al entorno. Concluimos que el cuello de botella de la visión-RL no es la *capacidad* de la representación sino la *asignación de crédito* a través de píxeles en un problema parcialmente observable, y que la destilación privilegiada lo esquiva con targets supervisados densos.

Index Terms—aprendizaje por refuerzo, clonación de comportamiento, destilación de políticas, conducción autónoma, aprendizaje privilegiado, randomización de dominio

I. INTRODUCCIÓN

Un agente de conducción autónoma que percibe el mundo *solo* a través de una cámara enfrenta un problema doblemente difícil: la observación visual es *parcial* —un frame congela la escena: no muestra qué hay tras la próxima curva ni cómo evoluciona el entorno— y la señal de aprendizaje es *escasa*, la recompensa por avanzar en pista. En este régimen, una red convolucional entrenada con RL tiende a encontrar un *atajo*: se aferra a la textura del fondo (la pared y el horizonte de la arena), que es constante durante el entrenamiento pero no lleva información útil de la calzada. El resultado es una política frágil que conduce mientras el fondo no cambie.

Atacamos el problema por dos vías complementarias. **Randomización de dominio del fondo**: rotamos la textura de la pared y el *skybox* por episodio, para que el fondo deje de ser una señal aprovechable. **Destilación privilegiada**: en lugar de aprender de la recompensa, el estudiante de visión imita las decisiones de un maestro que ya percibe la calzada de forma limpia —heredando *qué mirar*— siguiendo la línea de *Learning by Cheating* [1].

Nuestra contribución es un estudio controlado, con 5 seeds por modelo (25 modelos en total), que aísla el efecto de la

representación de la observación, dejando todo lo demás fijo. Mostramos que (i) la visión destilada iguala estadísticamente al maestro privilegiado; (ii) la visión-RL directa es poco confiable y la temporalidad la empeora; y (iii) la saliencia confirma que la ventaja es de invarianza al entorno.

II. TRABAJO RELACIONADO

La **destilación de un agente privilegiado** a uno de visión es la base directa de este trabajo: *Learning by Cheating* [1] entrena primero un agente con acceso al estado del simulador y luego lo clona a una política sensorimotora. La **clonación de comportamiento** ingenua sufre corrimiento de covariables, formalizado por DAGger [2]: el alumno visita estados que el maestro nunca demostró. DART [3] mitiga esto inyectando ruido en la acción del maestro durante la colecta, cubriendo estados de recuperación; usamos exactamente esta idea con $\sigma = 0.15$. La **randomización de dominio** [4] fuerza invarianza randomizando lo irrelevante —aquí, el fondo. El agente base se entrena con PPO [5] y el extractor visual es la NatureCNN [6]. El escenario está inspirado en la plataforma AWS DeepRacer [7].

III. MÉTODO

Las cinco variantes comparten entorno, recompensa, presupuesto (10M pasos) y configuración de PPO; **lo único que cambia es la observación** (Tabla I). La acción es un vector continuo de dos componentes —las velocidades normalizadas de las ruedas izquierda y derecha (tracción diferencial), cada una remapeada a $[v_{\min}, v_{\max}]$ rad/s— y la recompensa es densa: progreso sobre la pista menos penalizaciones, computada desde la misma imagen de cámara.

Tabla I
LAS CINCO REPRESENTACIONES DE LA OBSERVACIÓN.

Variante	Régimen	Observación
Geométrica	privilegiado	Vector de 9 features de percepción.
Visión 1 frame	visión-RL	CNN sobre un frame RGB crudo. La variante de visión más simple.
Visión apilada	visión-RL	Cuatro frames apilados para dar información temporal.
Visión + LSTM	visión-RL	Política recurrente: la memoria la aporta el LSTM.
Visión destilada	destilado (BC)	CNN de 1 frame entrenada por clonación para imitar al maestro geométrico.

III-A. El pipeline de destilación

Una misma cámara alimenta dos caminos (Fig. 1). El *baseline* entrena la visión con RL directo desde la recompensa. *Nuestro método* primero entrena un maestro geométrico privilegiado, colecta sus decisiones con ruido DART y entrena por clonación (MSE sobre la acción) un estudiante de visión que hereda *qué mirar*. La clonación de comportamiento **cambia la naturaleza del problema**: en lugar de optimizar la visión por refuerzo desde la recompensa —con su *asignación de crédito* (*credit assignment*) de alta varianza a través de píxeles— resuelve un aprendizaje *supervisado* directo con targets densos, mucho más fácil de optimizar. El estudiante usa *exactamente* la misma arquitectura (NatureCNN, 1 frame) que la variante Visión 1 frame, de modo que la única diferencia es el *régimen de entrenamiento*.




Figura 1. El pipeline. Una cámara alimenta dos caminos: arriba, nuestro método (maestro geométrico privilegiado → colecta con DART → clonación a un estudiante de visión); abajo, el baseline de visión-RL directo, que sobreajusta el fondo.

IV. SETUP EXPERIMENTAL

El simulador es Webots R2025a y el agente se implementa sobre Stable-Baselines3 (PPO) [5] y sb3-contrib (RecurrentPPO). Adoptamos PPO como algoritmo base por su estabilidad y eficiencia demostradas en control continuo y navegación autónoma. La observación de visión combina una imagen RGB $84 \times 84 \times 3$ (multiplicada por el número de frames apilados) con una lectura *propioceptiva* de velocidad del cuerpo (*forward* y *yaw-rate*, tomada del ground-truth del simulador); la observación geométrica reemplaza la imagen por un vector de 9 features de percepción —esas mismas 2 de velocidad más 7 de calzada (road-fraction, verde central y 5 offsets laterales de

look-ahead). Así, **todas las variantes comparten la velocidad propioceptiva**; lo único que cambia es cómo perciben la pista (imagen cruda vs. features explícitas). La política de visión es en consecuencia *MultiInput*: una NatureCNN sobre la imagen y un MLP sobre la velocidad. La randomización de dominio rota la textura de la pared y el *skybox* por episodio. La evaluación usa dos pistas no vistas (*track9*, *track10*; Fig. 2), 20 episodios por pista, con fondo aleatorio y seed de reinicio fija (*eval-seed 0*) para que todos los modelos vean exactamente la misma secuencia de episodios. Las tablas II y III listan los hiperparámetros reales de los runs finales.

ENTRENAMIENTO — 8 pistas (ejemplos)



EVALUACIÓN — 2 pistas no vistas (held-out)




Figura 2. Pistas del estudio (mapas top-down: verde=fuera de pista, asfalto negro, línea de centro amarilla). **Arriba**: tres de las ocho pistas de *entrenamiento* (una por episodio, con fondo aleatorio). **Abajo**: las dos pistas de *evaluación* —no vistas en entrenamiento— de la misma distribución pero con curvas más cerradas.

Tabla II
HIPERPARÁMETROS DE PPO (LAS CUATRO VARIANTES RL).

Algoritmo	PPO (Stable-Baselines3)
Política	MultiInput Actor-Critic (NatureCNN + MLP)
Pasos totales	1 000 000
Entornos paralelos	4
n_steps / rollout	256 (1024/actualización)
Batch · Épocas	128 · 5
Learning rate	5×10^{-4}
$\gamma \cdot clip \cdot ent \cdot vf$	$0.995 \cdot 0.2 \cdot 0.02 \cdot 0.5$
Normalización	VecNormalize (reward)
Seeds	0, 1, 2, 3, 4

Tabla III
HIPERPARÁMETROS DE LA DESTILACIÓN (CLONACIÓN DE COMPORTAMIENTO).

Objetivo	Clonación de comportamiento (MSE)
Maestro	Geométrico, misma seed que el alumno
Colecta	Apareada: limpia ($\sigma=0$) + DART ($\sigma=0.15$)
Pares (s, a)	$\sim 55\,000$ por seed
Épocas $\cdot$ LR	$30 \cdot 3 \times 10^{-4}$
Backbone	NatureCNN, 1 frame

V. RESULTADOS

Evaluamos las cinco variantes (25 modelos) sobre pistas no vistas con fondo aleatorio. La métrica principal es la fracción de vueltas completadas (*lap rate*). La Tabla IV resume el desempeño medio y la Fig. 3 lo grafica.




Figura 3. Lap rate en pistas no vistas por variante (5 seeds, fondo aleatorio). La geométrica y la destilada quedan arriba y con barras angostas; la visión-RL cae y, sobre todo, se vuelve *inestable*.

El hallazgo central: la **visión destilada alcanza al maestro privilegiado**. La media de vueltas completadas es 95.5% frente a 97.0% (IQM 97.5% vs. 98.3%; una diferencia de apenas 1.5 puntos), con intervalos de confianza *bootstrap* del 95% ampliamente solapados (Tabla IV). Ahora bien, que dos intervalos se solapen no *demuestra* que las variantes sean equivalentes; para evaluarlo de forma directa aplicamos un TOST (*two one-sided tests*) sobre el lap rate por seed, con un margen de equivalencia pre-especificado de ± 5 puntos: con $n=5$ el test **no llega a declarar equivalencia** ($p_{\text{TOST}} = 0.18$; IC del 90% de la diferencia $[-5.2, +8.2]$ puntos), lo que refleja el *escaso poder de cinco seeds* más que una diferencia real: un análisis de varianza muestra que el 60–80% de la dispersión es variabilidad *entre seeds* (irreducible con más episodios de evaluación), de modo que la equivalencia estricta solo quedaría establecida bajo un margen práctico más laxo (± 8 puntos) o con del orden de 20–30 seeds por condición. En síntesis: no detectamos una diferencia y el efecto es pequeño, pero *no afirmamos equivalencia estricta* a ± 5 puntos. Con esa cautela, la destilada es además el *conductor confiable más rápido*: recupera la competencia del agente privilegiado partiendo solo de píxeles.

V-A. *La visión-RL es una lotería; la destilación, no*

El promedio esconde lo esencial. La Tabla V muestra el lap rate por seed: las variantes temporales son **bimodales** — algunas seeds convergen y otras colapsan (de 5 a 100, de 0 a 82)— mientras que el maestro y la destilada rinden parejo en las cinco. La enorme varianza de apilada y LSTM es el síntoma: la temporalidad agrega *dificultad de optimización*, no desempeño. Diagnósticos de entrenamiento (divergencia de KL, *explained variance* negativa del crítico) confirman una optimización inestable. Las curvas de entrenamiento (Fig. 4) lo hacen visible: la visión-RL aprende más lento y con bandas más anchas que el maestro.

Tabla V
LAP RATE (%) POR SEED. VERDE ≥ 85 , ROJO < 50 .

Variante	s0	s1	s2	s3	s4
Geométrica	100	98	98	90	100
Visión destilada	100	92	100	100	85
Visión 1 frame	90	92	60	90	85
Visión apilada	38	90	5	55	100
Visión + LSTM	5	65	0	32	82




Figura 4. Curvas de entrenamiento de las variantes RL (5 seeds, banda = $\pm$ desvío). Izquierda: reward por episodio. Derecha: lap rate en pistas no vistas durante el entrenamiento. La destilada es supervisada y no aparece en estas curvas de RL.

VI. ANÁLISIS: QUÉ MIRA LA CNN

Para entender *por qué* la destilación funciona, calculamos saliencia por *guided backprop* [8]: el gradiente de la decisión (valor del crítico $V(s)$ y *steering*) respecto de los píxeles de entrada. Crucialmente, la saliencia se computa **sobre el mismo frame que se muestra** —una curva— y no como un promedio sobre frames distintos, que mezclaría rectas y curvas. La Fig. 5 compara las cuatro variantes de visión (todas seed 0).

Tabla IV

DESEMPEÑO EN PISTAS NO VISTAS (FONDO ALEATORIO), AGREGADO SOBRE LAS 5 SEEDS DE CADA VARIANTE. CADA COLUMNA NUMÉRICA REPORTA IQM [IC 95 %]: LA *media intercuartil* —PROMEDIA EL 50 % CENTRAL DE LAS SEEDS, DESCARTANDO EL 25 % MEJOR Y EL 25 % PEOR; MÁS ROBUSTA QUE LA MEDIA SIMPLE FRENTE A SEEDS QUE COLAPSAN— SEGUIDA, ENTRE CORCHETES, DE SU *intervalo de confianza del 95 %* ESTIMADO POR *bootstrap* DE PERCENTIL (2×10^4 REMUESTREOS). EN *lap rate* Y *reward* MÁS ALTO ES MEJOR; EN *off-track* Y *tiempo de vuelta*, MÁS BAJO. FILAS RESALTADAS: LAS DOS VARIANTES QUE RESUELVEN LA TAREA. EL TIEMPO DE VUELTA SE OMITE (—) DONDE CASI NO SE COMPLETAN VUELTAS.

Variante	Régimen	Lap rate (%)	Off-track (%)	Tiempo vuelta (s)	Reward/ep
Geométrica	privilegiado (RL)	98.3 [92.5, 100]	1.7 [0, 7.5]	173 [167, 205]	539 [513, 548]
Visión destilada	destilado (BC)	97.5 [87.5, 100]	2.5 [0, 9.2]	154 [145, 188]	490 [439, 512]
Visión 1 frame	visión-RL	88.3 [68.3, 91.7]	6.7 [1.7, 13.3]	201 [164, 226]	406 [380, 435]
Visión apilada	visión-RL	60.8 [15.8, 96.7]	28.3 [0.8, 67.5]	—	365 [335, 460]
Visión + LSTM	visión-RL	34.2 [1.7, 76.7]	51.7 [23.3, 78.3]	—	278 [241, 332]

Saliencia por-frame (guided backprop) — calculada sobre esta misma curva, sin promediar




Figura 5. Saliencia por *guided backprop* sobre una misma curva. Las tres variantes de visión-RL (1 frame, apilada, LSTM) encienden la saliencia en una franja sobre el **horizonte** —la pared y las montañas del fondo—: usan el entorno, constante en entrenamiento, como atajo. La **destilada** desplaza la atención hacia *abajo*, sobre la calzada y el borde curvo del carril, con el horizonte apagado: hereda del maestro geométrico *qué mirar*. Dentro de cada modelo, *value* y *steer* coinciden porque comparten el extractor CNN.

La lectura es directa: la visión-RL directa se apoya en el fondo, que correlaciona con la dirección del giro en el

set de entrenamiento pero desaparece bajo randomización; la destilación *decorrelaciona* la política del fondo, y por eso se sostiene.

VII. LIMITACIONES

El estudio es **solo en simulación**: no evaluamos transferencia a hardware real, y el maestro usa features extraídas dentro del simulador que en el mundo real habría que estimar con percepción —el problema difícil. Dicho esto, la saliencia sugiere una hipótesis *optimista* sobre la transferencia: como el estudiante destilado aprendió a *mirar la calzada e ignorar el fondo* —justo lo que la randomización vuelve inservible—, es un candidato mucho más prometedor para *sim-to-real* que la visión-RL directa, que colapsaría al desaparecer el fondo específico de Webots del que depende. La **familia de pistas es acotada** (dos pistas no vistas de la misma distribución) y la **randomización de dominio es parcial** (varía pared y skybox, no geometría, iluminación ni cámara), de modo que cierra *este* atajo y no todos los posibles. Por construcción, el **estudiante hereda el techo del maestro**: la mejora en tiempo de vuelta proviene de acciones más suaves, no de una política estrictamente superior. Finalmente, la bimodalidad de la visión-RL sugiere alta **sensibilidad a la seed**; no realizamos un barrido exhaustivo que pudiera rescatar algunas seeds colapsadas.

VIII. CONCLUSIÓN

Un agente privilegiado con percepción limpia de la calzada resuelve la tarea (97%), y *destilarlo* a un agente de visión recupera ese desempeño (95.5 %; una diferencia de 1.5 puntos, sin evidencia de superioridad de ninguno) y con mejor tiempo de vuelta. Entrenar la misma visión con RL directo es poco confiable, y la temporalidad la empeora. La randomización del fondo y la saliencia confirman que la ventaja es de *invarianza al entorno*: la destilada mira la calzada, no el horizonte. La lectura general es que el límite de la visión-RL no es la *capacidad* de la representación sino la *asignación de crédito* a través de píxeles en un problema parcialmente observable; la destilación privilegiada lo esquiva con targets supervisados densos del agente privilegiado. Código, modelos y una versión navegable del paper están disponibles en <https://github.com/fluchetti45/deepracer>.

REFERENCIAS

- [1] D. Chen, B. Zhou, V. Koltun, and P. Krähenbühl, “Learning by cheating,” in *Conference on Robot Learning (CoRL)*, 2019.
- [2] S. Ross, G. J. Gordon, and J. A. Bagnell, “A reduction of imitation learning and structured prediction to no-regret online learning,” in *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2011.
- [3] M. Laskey, J. Lee, R. Fox, A. Dragan, and K. Goldberg, “Dart: Noise injection for robust imitation learning,” in *Conference on Robot Learning (CoRL)*, 2017.
- [4] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, and P. Abbeel, “Domain randomization for transferring deep neural networks from simulation to the real world,” in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2017.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [6] V. Mnih, K. Kavukcuoglu, D. Silver *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [7] B. Balaji, S. Mallya, S. Genc *et al.*, “Deepracer: Autonomous racing platform for experimentation with sim2real reinforcement learning,” in *IEEE International Conference on Robotics and Automation (ICRA)*, 2020.
- [8] J. T. Springenberg, A. Dosovitskiy, T. Brox, and M. Riedmiller, “Striving for simplicity: The all convolutional net,” in *International Conference on Learning Representations (ICLR) Workshop*, 2015.